

# ANALISIS KUALITAS INSTRUMEN PENILAIAN HASIL BELAJAR SISWA PPLG SMKN 2 SEMARANG MENGGUNAKAN RASCH MODEL

Nur Diana Faiza<sup>1</sup>;  
Dewi Hariyani<sup>2</sup>  
Fitria Ekarini<sup>3</sup>  
Djuniadi Djuniadi<sup>4</sup>

<sup>1,2,3,4</sup> Universitas Negeri Semarang

Alamat Korespondensi  
dianafaiza@students.unnes.ac.id

## ABSTRAK

Tujuan dari penelitian ini adalah untuk menganalisis kualitas instrumen penilaian hasil belajar siswa kelas X PPLG di SMK Negeri 2 Semarang menggunakan Model Rasch. Metode penelitian yang digunakan adalah deskriptif kuantitatif. Penelitian ini melibatkan sampel sebanyak 36 siswa kelas 10 dari SMKN 2 Semarang yang dipilih melalui teknik purposive sampling. Instrumen terdiri dari 20 butir soal pilihan ganda yang telah melalui validasi ahli dan dianalisis menggunakan perangkat lunak jMetrik. Hasil penelitian menunjukkan validitas isi yang sangat tinggi dengan nilai Aiken's V berkisar antara 0,88 hingga 1,00. Analisis Rasch menunjukkan reliabilitas butir yang baik (0,80) dengan rentang kesukaran yang luas (-3,48 hingga 2,02 logit). Meskipun sebagian besar butir cocok (fit) dengan model, teridentifikasi beberapa butir yang misfit atau terlalu mudah. Walaupun reliabilitas responden tergolong rendah (0,26) akibat homogenitas sampel, instrumen ini dinyatakan valid secara statistik dan layak digunakan untuk mengukur kompetensi siswa pada program keahlian PPLG.

**Kata Kunci** instrumen penilaian, hasil belajar, model rasch, program keahlian pplg, validitas.

## I. Pendahuluan

Pendidikan vokasi pada jenjang Sekolah Menengah Kejuruan (SMK) berperan penting dalam menyiapkan lulusan yang siap memasuki dunia kerja, khususnya di sektor teknologi informasi. Program keahlian Pengembangan Perangkat Lunak dan Gim (PPLG) menuntut penguasaan kompetensi teknis seperti pemrograman, pengembangan aplikasi, dan desain permainan digital. Oleh karena itu, penilaian hasil belajar pada program PPLG harus mampu menggambarkan secara akurat tingkat penguasaan kompetensi tersebut sehingga dapat menjadi dasar pengambilan keputusan pembelajaran dan pengembangan kurikulum (Prasetya & Pratama, 2023). Penilaian tersebut sangat ditentukan oleh kualitas instrumen yang digunakan, karena instrumen menjadi alat utama untuk mengukur capaian kompetensi secara objektif dan terstandar.

Untuk memastikan instrumen penilaian memberi keluaran yang sahih, penyusunan instrumen harus didasarkan pada kisi-kisi, indikator kompetensi, dan uji validitas isi oleh ahli. Instrumen yang disusun tanpa tahapan validasi tersebut berisiko menghasilkan skor yang tidak mencerminkan kemampuan nyata siswa (Noorkholisoh et al., 2024). Kebutuhan akan instrumen yang memadai menjadi lebih krusial pada PPLG karena karakter kompetensi yang aplikatif dan berorientasi pada performa seperti berpikir komputasional, problem-solving, dan kemampuan teknis. Oleh karena itu, instrumen harus dapat mengukur aspek kognitif dan praktik secara sensitif dan akurat meskipun ada variasi kemampuan pada peserta didik.

Sejumlah penelitian sebelumnya menunjukkan bahwa kelemahan umum dalam praktik penilaian guru adalah penggunaan instrumen yang belum melalui proses telaah ahli maupun uji empiris, sehingga kualitas butir soal kerap kali tidak memenuhi standar psikometrik (Adi et al., 2022). Hal ini juga ditegaskan oleh penelitian lainnya yang menyoroti pentingnya pengembangan instrumen berbasis teknologi dan telaah kebutuhan dalam evaluasi pembelajaran. Studi oleh Larasati, Prihatin, & Djuniadi (2021) menunjukkan bahwa evaluasi berbasis TIK menuntut

instrumen berkualitas agar data penilaian dapat mendukung pengambilan keputusan secara lebih akurat dan adaptif. Sedangkan pada penelitian yang dilakukan oleh Fardiana, Supriyadi, & Djuniadi (2023) yang menemukan bahwa pengembangan instrumen asesmen berbasis website memerlukan validasi menyeluruh karena karakter digital assessment menuntut konsistensi butir dan struktur pengukuran yang kuat. Temuan-temuan tersebut menegaskan bahwa peningkatan kualitas instrumen, baik secara konseptual maupun empiris, merupakan kebutuhan mendesak dalam pengembangan evaluasi pendidikan vokasional.

Secara metodologis, banyak praktisi pendidikan masih mengandalkan Teori Tes Klasik (Classical Test Theory/CTT) untuk analisis item. Meskipun CTT sederhana dan praktis, CTT memiliki kelemahan penting: parameter item (mis. tingkat kesukaran, daya beda) sangat dipengaruhi oleh sampel yang diuji sehingga tidak selalu stabil ketika instrumen diujikan pada populasi berbeda (Susongko et al., 2021). Selain itu, CTT tidak menyediakan indikator fit item terhadap model pengukuran, sehingga sulit mendeteksi butir-butir yang berperilaku tidak konsisten (mis. misfitting items). Akibatnya, analisis berbasis CTT dapat menutup masalah psikometrik yang hanya akan terlihat ketika menggunakan pendekatan lain seperti IRT/Rasch.

Sebaliknya, Model Rasch yang merupakan bagian dari pendekatan Item Response Theory (IRT), menawarkan solusi atas keterbatasan CTT. Model Rasch memisahkan parameter kemampuan peserta dan tingkat kesukaran item sehingga estimasi menjadi relatif independen terhadap sampel. Dengan Rasch peneliti dapat menguji kecocokan item melalui statistik Infit/Outfit Mean Square (MNSQ), mengukur korelasi point-measure, menaksir tingkat kesukaran dalam satuan logit, serta menyusun peta item-person (Wright map) yang menggambarkan kesesuaian antara distribusi kemampuan peserta dan distribusi tingkat kesukaran item (Fiskawarni et al., 2024). Berbagai penelitian seperti penelitian oleh Noorkholisoh et al., (2024) dan Fiskawarni et al., (2024) menunjukkan efektivitas Model Rasch dalam mengidentifikasi butir bermasalah, menilai reliabilitas instrumen, serta memastikan unidimensionalitas konstruk. Dalam konteks pendidikan vokasi, Adi et al., (2022) membuktikan bahwa analisis Rasch mampu memberikan rekomendasi revisi butir untuk instrumen matematika SMK sehingga menjadi lebih valid dan reliabel. Analisis semacam ini memungkinkan penyusun instrumen memperoleh bukti empiris yang kuat mengenai kualitas butir dan keandalan instrumen.

Bukti empiris dari penelitian-penelitian terdahulu menunjukkan bahwa penerapan Model Rasch efektif untuk mengevaluasi instrumen pada berbagai ranah dan jenjang pendidikan. Sejalan dengan itu, Larasati et al., (2021) berpendapat bahwa penggunaan perangkat analisis modern seperti jMetrik memberikan peluang bagi guru dan peneliti untuk melakukan pemrosesan data instrumen secara lebih akurat, transparan, dan efisien. Kemudahan analisis Rasch melalui jMetrik memperkuat implementasi asesmen berbasis data, khususnya di lingkungan pendidikan vokasi. Selain dukungan perangkat analisis tersebut, berbagai studi juga menunjukkan bahwa Model Rasch mampu menghasilkan instrumen yang unidimensional, reliabel, dan fit terhadap model, seperti pada pengembangan tes kreativitas siswa sekolah dasar (Noorkholisoh et al., 2024). Penelitian lain pada instrumen literasi sains dan literasi energi juga memperlihatkan bahwa Rasch membantu menilai dan merevisi butir sehingga instrumen menjadi lebih valid dan reliabel (Fiskawarni et al., 2024; Susongko et al., 2021). Dalam konteks pendidikan vokasi, analisis Rasch terhadap butir matematika SMK menunjukkan bahwa sebagian besar butir dapat diandalkan dan memberikan rekomendasi perbaikan pada item yang tidak fit (Adi et al., 2022). Dengan demikian, secara metodologis Model Rasch relevan dan aplikatif untuk analisis instrumen pada PPLG.

Berdasarkan kondisi tersebut, tujuan dari penelitian ini adalah untuk menganalisis kualitas instrumen penilaian hasil belajar siswa kelas X PPLG di SMK Negeri 2 Semarang. Analisis difokuskan pada tiga aspek utama, yaitu: (1) validitas isi instrumen yang dinilai oleh para ahli untuk memastikan kesesuaian dan keterwakilan butir, (2) reliabilitas instrumen yang diukur

secara empiris untuk menilai konsistensi internal, serta (3) kualitas butir soal yang dianalisis menggunakan Model Rasch melalui jMetrik, mencakup parameter seperti reliabilitas item dan person, nilai Infit dan Outfit Mean Square (MNSQ), Z-standard (ZSTD), serta estimasi tingkat kesukaran yang dianalisis menggunakan grafik IRT Plot. Hasil evaluasi ini diharapkan memberikan gambaran komprehensif mengenai kelayakan instrumen serta menjadi dasar perbaikan dalam penyusunan soal yang lebih valid, reliabel, dan sesuai dengan kebutuhan asesmen pada program keahlian PPLG.

Kebaruan penelitian ini terletak pada penerapan Model Rasch untuk menilai instrumen penilaian hasil belajar pada kompetensi PPLG di SMK, yaitu suatu domain vokasi yang relatif sedikit ditelaah dengan pendekatan psikometrik modern. Selain itu, penelitian ini menggunakan jMetrik sebagai alat analisis yang bersifat aksesibel dan praktis bagi peneliti dan guru di lingkungan pendidikan vokasi. Dengan demikian, penelitian ini diharapkan dapat memberikan kontribusi metodologis dan praktis bagi pengembangan instrumen penilaian di pendidikan vokasi, khususnya pada program PPLG.

## 2. Metode

Penelitian ini menggunakan pendekatan kuantitatif deskriptif untuk menganalisis kualitas instrumen penilaian hasil belajar siswa kelas X PPLG, meliputi validitas isi, reliabilitas, dan karakteristik butir menggunakan Model Rasch. Pendekatan kuantitatif dipilih karena analisis statistik memungkinkan pengukuran objektif parameter psikometrik instrumen. Pendekatan kuantitatif ini selaras dengan praktik umum dalam pengembangan instrumen berbasis Rasch, mengingat model ini menghasilkan estimasi parameter item dan person secara objektif serta memberikan indikator fit yang diperlukan dalam penilaian kualitas instrumen (Holster, 2023). Validitas isi melalui expert judgment digunakan sebagai landasan untuk memastikan setiap butir instrumen merepresentasikan kompetensi PPLG secara tepat, sebagaimana ditekankan dalam kajian metodologis mengenai validitas konten (Almanasreh et al., 2019). Validitas isi melalui expert judgment digunakan sebagai landasan untuk memastikan setiap butir instrumen merepresentasikan kompetensi PPLG secara tepat.

Data penelitian berupa data kuantitatif primer yang dikumpulkan dari dua kelompok sumber. Pertama, data validasi ahli berupa skor penilaian menggunakan skala Likert 1–5 yang mencakup aspek kesesuaian materi, kejelasan rumusan soal, ketepatan tingkat kognitif, kesesuaian opsi jawaban, tata bahasa, dan kualitas keseluruhan. Validasi dilakukan oleh dua ahli yang memiliki kompetensi di bidang pengembangan perangkat lunak dan gim, terdiri atas dosen program Pendidikan Teknik Informatika dan Komputer serta guru pada konsentrasi keahlian PPLG. Pemilihan ahli dilakukan secara purposif dengan mempertimbangkan latar belakang akademik, pengalaman mengajar, serta kompetensi dalam menilai instrumen pendidikan, sebagaimana dijelaskan dalam pedoman penetapan expert judgment (Masuwai et al., 2024). Data validasi bersifat ordinal dan dianalisis menggunakan indeks Aiken's V untuk menilai konsistensi dan kesepakatan ahli terhadap kelayakan isi setiap butir, sesuai dengan penggunaan Aiken's V dalam penelitian pengembangan instrumen pendidikan (Hamsyah et al., 2021). Skor penilaian yang diberikan oleh ahli kemudian dianalisis menggunakan Statistik V'Aiken dengan rumus:

$$V = \frac{\sum S}{[n(c - 1)]}$$

keterangan:

V = validitas

S = r – lo


lo = angka penilaian validitas yang terendah

c = angka penilaian validitas yang tertinggi

$r$  = angka yang diberikan oleh seorang penilai  
 $n$  = banyaknya validator

Kedua, data empiris berupa respons siswa terhadap 20 butir soal pilihan ganda yang disusun berdasarkan kisi-kisi capaian pembelajaran (Adi et al., 2022), yang dikodekan secara dikotomis (1 = benar, 0 = salah) untuk dianalisis menggunakan Model Rasch. Setiap butir soal terdiri dari satu stem, satu jawaban benar, dan empat pengecoh yang disusun untuk membedakan kemampuan siswa secara optimal. Sampel penelitian terdiri dari 36 siswa kelas X kompetensi keahlian PPLG SMK N 2 Semarang, yang dipilih secara purposif karena mereka merupakan kelompok sasaran instrumen yang diuji. Penerapan uji empiris ini sejalan dengan praktik evaluasi butir dalam penelitian berbasis Rasch untuk memastikan kualitas instrumen dalam kondisi aktual (Susongko et al., 2021).

Analisis data dalam penelitian ini dilakukan melalui tiga tahap utama yang diadaptasi dari Fiskawarni et al., (2024). Secara umum prosedur analisis yang dilakukan pada penelitian ini disajikan pada Gambar 1.



Gambar 1. Rancangan Prosedur Penelitian

Pada Gambar 1, tahap pertama yang dilakukan adalah melakukan expert judgment untuk memvalidasi instrumen berdasarkan penilaian ahli. Para ahli memberikan skor 1–5 terhadap enam aspek kualitas butir, yaitu kesesuaian materi, kejelasan rumusan, ketepatan tingkat kognitif, kesesuaian opsi jawaban, tata bahasa, dan kualitas keseluruhan. Skor tersebut dianalisis

menggunakan indeks Aiken's  $V$  untuk menentukan tingkat kesepakatan ahli, sebagaimana digunakan dalam penelitian validitas instrumen pendidikan (Marselina et al., 2021). Secara umum, kriteria skor validitas menggunakan Aiken's  $V$  diklasifikasikan dalam Tabel 1.

Tabel 1. Kriteria Validitas

| Hasil Validitas   | Kriteria Validitas |
|-------------------|--------------------|
| $0,80 < V < 1,00$ | Sangat Tinggi      |
| $0,60 < V < 0,80$ | Tinggi             |
| $0,40 < V < 0,60$ | Cukup              |
| $0,20 < V < 0,40$ | Rendah             |
| $0,00 < V < 0,20$ | Sangat Rendah      |

Sumber: Fadillah dalam Hamsyah et al., (2021)

Tabel 1 menunjukkan kriteria validitas berdasarkan nilai Aiken's  $V$  dengan lima kategori, yaitu sangat tinggi (0,80–1,00), tinggi (0,60–0,80), cukup (0,40–0,60), rendah (0,20–0,40), dan sangat rendah (0,00–0,20). Semakin besar nilai  $V$ , semakin tinggi tingkat kesepakatan ahli terhadap kualitas butir instrumen. Berdasarkan kriteria tersebut, butir dinyatakan valid secara isi apabila memiliki nilai  $V$  di atas 0,40, sedangkan butir di bawah batas tersebut perlu direvisi sebelum digunakan pada tahap uji coba empiris.

Tahap kedua adalah uji coba empiris instrumen kepada 36 siswa kelas X PPLG SMK N 2 Semarang. Siswa mengerjakan 20 butir soal pilihan ganda, dan responsnya dikodekan dalam format dikotomis (1 = benar, 0 = salah). Data empiris ini digunakan untuk melihat bagaimana setiap butir berfungsi dalam kondisi nyata, sebagaimana dianjurkan dalam penelitian pengembangan instrumen berbasis Rasch dalam konteks pendidikan (Hamdu et al., 2020).

Tahap ketiga adalah analisis Rasch menggunakan jMetrik untuk menilai kualitas psikometrik butir. Analisis mencakup perhitungan reliabilitas item dan person, nilai Infit dan Outfit Mean Square (MNSQ), Z-standard (ZSTD), serta estimasi tingkat kesukaran yang dianalisis menggunakan grafik IRT Plot. Kriteria kelayakan mengikuti batas umum, yaitu MNSQ berada pada rentang 0,50–1,50 dan ZSTD berada antara –2 hingga +2 sebagai indikator kesesuaian pola respons terhadap model. Selain itu, grafik *IRT Plot* dan *Item Map* dianalisis untuk melihat pola karakteristik butir serta distribusi kesukaran item terhadap kemampuan peserta, sebagaimana direkomendasikan dalam kajian Rasch terkait evaluasi instrumen pendidikan (Alhadabi & Aldhafri, 2021). Dalam software Jmetrik Outfit mean square (MNSQ) dikenal dengan WMS (Weighted mean square) dan ZTSD dikenal dengan Standardized WMS. Hasil analisis digunakan untuk mengidentifikasi butir yang tidak fit dan memberikan rekomendasi perbaikan.

### 3. Hasil dan Pembahasan

Sebelum instrumen diujikan kepada sampel, dilakukan validasi isi terlebih dahulu. Menurut Almanasreh et al. (2019) validasi isi didefinisikan sebagai sejauh mana elemen-elemen instrumen penilaian relevan dan representatif terhadap konstruk yang ditargetkan untuk tujuan penelitian tertentu. Validasi isi pada penelitian ini diperoleh melalui expert judgment yang melibatkan dua orang ahli, yaitu dosen dan guru pengampu. Validasi ini menilai aspek kesesuaian materi, kejelasan rumusan soal, ketepatan tingkat kognitif, kesesuaian opsi jawaban, tata bahasa, dan kualitas dari keseluruhan item. Berdasarkan hasil penilaian validator, dilakukan perhitungan menggunakan formula Aiken's  $V$ . Adapun hasil validasi instrumen penilaian hasil belajar siswa disajikan pada Tabel 2.

Tabel 2. Analisis Validasi Isi

| No. Item | Aiken's V | Kategori |
|----------|-----------|----------|
| 1        | 0,88      | Valid    |
| 2        | 0,88      | Valid    |
| 3        | 0,88      | Valid    |
| 4        | 1,00      | Valid    |
| 5        | 0,88      | Valid    |
| 6        | 0,88      | Valid    |
| 7        | 1,00      | Valid    |
| 8        | 0,88      | Valid    |
| 9        | 0,88      | Valid    |
| 10       | 0,88      | Valid    |
| 11       | 1,00      | Valid    |
| 12       | 0,88      | Valid    |
| 13       | 1,00      | Valid    |
| 14       | 1,00      | Valid    |
| 15       | 0,88      | Valid    |
| 16       | 0,88      | Valid    |
| 17       | 1,00      | Valid    |
| 18       | 0,88      | Valid    |
| 19       | 1,00      | Valid    |
| 20       | 0,88      | Valid    |

Tabel 2 menunjukkan bahwa instrumen penilaian hasil belajar siswa memiliki indeks V Aiken di rentang 0,88 – 1,00. Terdapat 35% butir dari soal yang memperoleh indeks V Aiken's sebesar 1,00 dan 65% butir soal memperoleh indeks sebesar 0,88. Berdasarkan data diatas, maka dapat dikatakan bahwa 20 butir soal instrumen penilaian hasil belajar yang telah disusun tergolong valid. Hal ini ditegaskan Azwar dalam Danni (2022) bahwa butir item dikatakan valid apabila indeks V Aiken's  $> 0,4$ . Dengan demikian, instrumen penilaian hasil belajar siswa kelas X PPLG terbukti dapat digunakan untuk mengukur kemampuan siswa. Di dukung dengan hasil penilain ahli yang menguatkan bahwa instrumen penilaian hasil belajar siswa yang disusun layak digunakan untuk mengukur kemampuan belajar siswa.

Tahap selanjutnya, instrumen diuji cobakan kepada 36 siswa kelas X dari SMKN 2 Semarang. Untuk mengetahui kualitas instrumen secara lebih mendalam, data respons siswa kemudian dianalisis menggunakan Rasch Model. Statistik hasil analisis ditampilkan pada Tabel 3 berikut.

Tabel 3. Scale Quality Statistics

| Statistic          | Items  | Persons |
|--------------------|--------|---------|
| Observed Variance  | 1,7313 | 0,5650  |
| Observed Std. Dev. | 1,3158 | 0,7517  |
| Mean Square Error  | 0,3418 | 0,4158  |
| Root MSE           | 0,5847 | 0,6448  |
| Adjusted Variance  | 1,3895 | 0,14922 |
| Adjusted Std. Dev. | 1,1788 | 0,3862  |
| Separation Index   | 2,0162 | 0,5989  |

|                  |        |         |
|------------------|--------|---------|
| Number of Strata | 3,0216 | 1,1319  |
| Reliability      | 0,8026 | 0,02640 |

Tabel 3 menampilkan tentang ringkasan statistik utama hasil analisis Rasch Model yang menggambarkan kualitas item dan kemampuan responden dalam instrumen yang diuji. Nilai observed dan adjusted variance serta standard deviation menunjukkan keragaman data sebelum dan sesudah koreksi kesalahan pengukuran melalui mean square error. Pada sisi item, separation index sebesar 2,0162 dengan strata 3,0216 serta nilai item reliability sebesar 0,8026 menunjukkan bahwa kualitas butir soal tergolong cukup bagus dan konsisten dalam mengukur materi yang diujikan (Sumintono & Widhiarso, 2015). Namun, nilai person separation yang rendah (0,5989) dengan strata 1,1319 serta person reliability sebesar 0,2640 mengindikasikan bahwa variasi kemampuan responden kurang terdeteksi, yang kemungkinan disebabkan oleh homogenitas kemampuan siswa pada sampel uji coba yang berjumlah 36 orang. Kondisi ini umum terjadi pada konteks penilaian kelas dengan sampel kecil, sehingga instrumen perlu diperkaya dengan butir tambahan agar lebih sensitif dalam membedakan tingkat kemampuan siswa.

Setelah memperoleh gambaran umum mengenai kualitas instrumen melalui statistik utama Rasch Model, analisis selanjutnya difokuskan pada karakteristik setiap butir soal. Detail parameter item, meliputi tingkat kesulitan, kesalahan pengukuran, serta nilai outfit dan infit dalam bentuk Mean Square dan Standardized, disajikan pada Tabel 4 berikut.


Tabel 4. Item Statistics

| Butir | Difficulty | Std. Error | WMS  | Std. WMS | UMS  | Std.UMS |
|-------|------------|------------|------|----------|------|---------|
| 1     | 1,09       | 0,37       | 1,01 | 0.12     | 0.97 | -0.12   |
| 2     | -1,50      | 0,74       | 1,07 | 0.31     | 1.11 | 0.42    |
| 3     | 0,81       | 0,38       | 1,06 | 0.50     | 1.08 | 0.43    |
| 4     | 1,09       | 0,37       | 0,93 | -0.62    | 0.87 | -0.74   |
| 5     | 0,95       | 0,37       | 0,82 | -1.57    | 0.75 | -1.43   |
| 6     | -2,24      | 1,02       | 1,04 | 0.35     | 1.06 | 0.47    |
| 7     | -0,71      | 0,55       | 0,81 | -0.38    | 0.59 | -0.66   |
| 8     | -0,44      | 0,50       | 1,07 | 0.33     | 0.95 | 0.0     |
| 9     | 0,67       | 0,38       | 1,02 | 0.17     | 0.97 | -0.06   |
| 10    | -0,44      | 0,50       | 1,00 | 0.12     | 1.99 | 1.78    |
| 11    | -2,24      | 1,02       | 1,04 | 0.35     | 1.06 | 0.47    |
| 12    | -3,48      | 1,84       | 0,01 | -1.13    | 0.01 | -1.21   |
| 13    | 0,81       | 0,38       | 1,10 | 0.79     | 1.09 | 0.51    |
| 14    | -3,48      | 1,84       | 0,01 | -1.13    | 0.01 | -1.21   |
| 15    | -2,24      | 1,02       | 0,85 | 0.14     | 0.24 | -0.44   |
| 16    | 1,88       | 0,37       | 0,94 | -0.51    | 1.02 | 0.15    |
| 17    | 2,02       | 0,37       | 1,04 | 0.36     | 1.03 | 0.22    |
| 18    | -0,21      | 0,47       | 1,08 | 0.38     | 1.11 | 0.40    |
| 19    | 0,36       | 0,41       | 1,10 | 0,55     | 1.21 | 0.77    |
| 20    | 0,36       | 0,41       | 0,96 | -0,15    | 0.97 | -0,02   |

Tabel 4 menyajikan ringkasan analisis 20 butir menggunakan Rasch Model berdasarkan nilai Outfit Mean Square (WMS) sebagai indikator utama kelayakan butir. Berdasarkan kriteria *fit* menurut Bond et al., (2021), butir dikatakan sesuai apabila memiliki nilai WMS berada pada

rentang 0,5 hingga 1,5, nilai di bawah 0,5 menunjukkan *overfit* karena respons terlalu dapat diprediksi sehingga tidak memberikan informasi baru, sementara nilai di atas 1,5 mencerminkan *misfit* atau ketidaksesuaian pola respons terhadap model. Hasil analisis menunjukkan bahwa sebagian besar butir memiliki nilai WMS antara 0,81 hingga 1,11, sehingga tergolong *fit* dan berfungsi secara optimal dalam mengukur konstruk yang ditargetkan. Namun demikian, dua butir yaitu butir 12 dan 14 memiliki nilai WMS yang sangat rendah (0,01), yang menunjukkan *overfit* ekstrem dan mengindikasikan bahwa kedua butir tersebut terlalu mudah ditebak atau tidak memberikan variasi informasi yang memadai dibandingkan butir lain. Tidak ditemukan butir dengan nilai WMS di atas 1,5, sehingga tidak ada item yang termasuk kategori *misfit*. Secara keseluruhan, struktur instrumen menunjukkan kualitas butir yang baik, namun butir 12 dan 14 perlu direvisi atau ditinjau ulang agar tidak mengganggu keseimbangan informasi dalam instrumen.

Untuk memperoleh gambaran yang lebih mendalam mengenai karakteristik masing-masing butir, dilakukan analisis *Item Response Theory* melalui tampilan IRT Plot. Grafik ini menunjukkan hubungan antara kemampuan peserta ( $\theta$ ) dan probabilitas menjawab benar, sekaligus memberikan informasi mengenai seberapa besar kontribusi item terhadap keseluruhan tes. IRT Plot untuk butir 17 dan 14 disajikan dalam Gambar 2 berikut.




Gambar 2. IRT Plot Butir 17 dan 14

Gambar 2. menunjukkan hubungan antara tingkat kemampuan (ability) dan probabilitas respon benar untuk item 17 dan 14. Berdasarkan IRT Plot butir 17, kurva karakteristik item menunjukkan pola yang meningkat secara proporsional seiring bertambahnya kemampuan ( $\theta$ ), dengan titik belok utama berada pada rentang kemampuan sekitar 1 hingga 2. Hal ini mengindikasikan bahwa butir 17 memiliki tingkat kesukaran sedang cenderung sulit, sehingga memberikan informasi maksimal pada peserta dengan kemampuan menengah ke atas. Kurva informasi juga menunjukkan puncak pada  $\theta$  sekitar 2, yang berarti butir ini efektif dalam membedakan peserta pada tingkat kemampuan tersebut. Sebaliknya, butir 14 memperlihatkan kurva karakteristik item yang bergeser jauh ke sisi kiri grafik, menunjukkan bahwa probabilitas menjawab benar mencapai nilai tinggi meskipun kemampuan peserta berada pada rentang sangat rendah ( $\theta$  sekitar  $-3$ ). Kondisi ini mengindikasikan bahwa butir 14 tergolong sangat mudah dan tidak mampu memberikan informasi pada peserta berkemampuan sedang maupun tinggi. Kurva informasi untuk butir 14 juga menunjukkan bahwa kontribusinya sangat rendah di hampir seluruh rentang kemampuan. Secara keseluruhan, analisis IRT Plot menegaskan bahwa butir 17 berfungsi dengan baik dalam memberikan informasi tes, sedangkan



butir 14 perlu direvisi karena tingkat kesukarannya terlalu rendah dan tidak memberikan informasi yang memadai dalam konteks pengukuran.


Sebelum dilakukan interpretasi lebih lanjut, analisis instrumen dilengkapi dengan penyajian IRT Plot yang menggambarkan hubungan antara kemampuan laten responden ( $\theta$ ) dan karakteristik tes secara keseluruhan. Visualisasi ini mencakup Kurva Karakteristik Tes (TCC) serta Fungsi Informasi Tes (TIF), yang secara komplementer memberikan gambaran mengenai pola peningkatan skor yang diharapkan dan tingkat presisi pengukuran pada setiap rentang kemampuan. Plot tersebut berfungsi sebagai dasar untuk memahami sejauh mana instrumen mampu mengukur kemampuan responden secara akurat pada berbagai level  $\theta$ , yang disajikan dalam Gambar 3.



Gambar 3. Pearson Plot

Berdasarkan Gambar 3. Kurva Karakteristik Tes (TCC), yang direpresentasikan dengan garis sigmoidal monokromatik, menunjukkan peningkatan Skor Benar yang Diharapkan (*Expected True Score*) secara monoton seiring dengan peningkatan nilai  $\theta$ , mencapai asimtot mendekati 20, konsisten dengan sifat instrumen yang mengukur kontinum kemampuan. Sementara itu, Fungsi Informasi Tes (TIF), yang ditunjukkan oleh kurva garis putus-putus, menggambarkan variasi tingkat presisi pengukuran. Puncak TIF berada pada rentang  $\theta$  sekitar 0 hingga 1, menandakan bahwa instrumen ini memberikan informasi maksimum dan memiliki keandalan tertinggi pada kelompok individu dengan kemampuan rata-rata hingga sedikit di atas rata-rata. Sebaliknya, penurunan TIF yang tajam pada nilai  $\theta$  yang sangat rendah atau sangat tinggi menunjukkan bahwa instrumen kurang efektif dalam membedakan kemampuan peserta pada area ekstrem tersebut, yang menjadi aspek penting dalam menilai validitas dan kegunaan tes.

Untuk melengkapi analisis parameter item dan kemampuan responden, pemetaan posisi item terhadap distribusi kemampuan peserta disajikan melalui *Item Map*. Visualisasi ini memberikan gambaran komprehensif mengenai keselarasan tingkat kesulitan item dengan kemampuan responden, serta mengidentifikasi potensi ketidakseimbangan struktur instrumen. *Item Map* tersebut disajikan pada Gambar 4.



Gambar 4. Item Map

Gambar 4. menyajikan Peta Item yang memvisualisasikan kalibrasi butir (item) dan kemampuan individu (person) pada skala yang sama, yaitu *Logits* (sumbu Y). Bagian kiri adalah histogram yang menunjukkan kepadatan kemampuan individu (Person Density), di mana sebaran kemampuan individu cenderung terpusat pada rentang *Logits* positif, khususnya antara +0.5 hingga +2.5. Hal ini mengindikasikan bahwa sebagian besar individu yang mengikuti tes memiliki kemampuan rata-rata hingga di atas rata-rata. Sementara itu, panel kanan menunjukkan persebaran butir, di mana setiap simbol merepresentasikan lokasi kesulitan satu butir pada skala *Logits*. Butir-butir tersebar luas mulai dari *Logits* yang sangat mudah (sekitar -3.0) hingga *Logits* yang sangat sulit (sekitar +2.5). Analisis komparatif menunjukkan adanya kesenjangan cakupan antara kemampuan individu dan kesulitan butir. Meskipun sebaran kemampuan individu terpusat di tengah-atas, terdapat butir-butir yang jauh lebih sulit (di atas *Logits* +2.0) yang hanya dapat dicapai oleh sedikit individu, dan butir-butir yang sangat mudah (di bawah *Logits* -2.0) yang berada jauh di bawah kemampuan mayoritas individu. Idealnya, untuk efisiensi pengukuran maksimum, sebaran kesulitan butir seharusnya selaras dengan sebaran kemampuan individu, khususnya di puncak kepadatan, guna memastikan bahwa tes mengukur secara optimal kemampuan mayoritas peserta, sesuai dengan prinsip inti dalam Model Rasch yang menghendaki kecocokan antara parameter butir dan person pada skala *Logits* (Bond et al., 2021).

## Pembahasan

## 4. Kesimpulan

Penelitian ini bertujuan menilai kualitas instrumen penilaian hasil belajar siswa kelas X PPLG di SMK Negeri 2 Semarang melalui analisis validitas isi, reliabilitas, dan karakteristik butir menggunakan Model Rasch. Berdasarkan validasi ahli, seluruh butir soal dinyatakan layak secara isi dengan nilai Aiken's V berada pada rentang 0,88–1,00 sehingga memenuhi kesesuaian terhadap indikator pembelajaran PPLG. Analisis empiris dengan Model Rasch menunjukkan bahwa item memiliki sebaran tingkat kesukaran yang luas dari -3,48 hingga 2,02, sehingga mampu mengukur kemampuan siswa pada rentang rendah hingga tinggi. Sebagian besar butir

menunjukkan nilai Infit dan Outfit MNSQ dalam batas kelayakan model, meskipun terdapat beberapa item yang terlalu mudah atau menunjukkan pola respons ekstrem sehingga direkomendasikan untuk direvisi.

Instrumen memiliki reliabilitas butir yang baik (0,8026) dengan tiga strata kesulitan item, meskipun reliabilitas peserta masih rendah (0,2640) yang mengindikasikan homogenitas kemampuan siswa pada sampel penelitian. Korelasi yang sangat kuat antara skor total dan kemampuan logit ( $r = 0,9534$ ) menunjukkan bahwa instrumen mampu menghasilkan estimasi kemampuan yang konsisten dengan ukuran performa nyata siswa.

Berdasarkan keseluruhan temuan, instrumen ini dinilai layak digunakan sebagai alat ukur hasil belajar pada kompetensi PPLG kelas X serta memberikan informasi diagnostik yang bermanfaat bagi guru dalam mengevaluasi dan meningkatkan kualitas pembelajaran. Secara ilmiah, penelitian ini berkontribusi dalam memperkuat praktik pengembangan instrumen penilaian di pendidikan vokasi dengan pendekatan psikometrik modern berbasis Rasch yang lebih objektif dibandingkan analisis konvensional.

## 5. Referensi

- Adi, N. R. M., Amaruddin, H., Adi, H. M. M., & A, I. L. Q. (2022). Validity and Reliability Analysis Using the Rasch Model to Measure the Quality of Mathematics Test Items of Vocational High Schools. *Journal of Educational Research and Evaluation*, 11(1), 103–113.
- Alhadabi, A., & Aldhafri, S. (2021). A Rasch Model Analysis of the Psychometric Properties of the Student- Teacher Relationship Scale among Middle School Students. *European Journal of Educational Research*, 10(2), 957–973. <https://doi.org/10.12973/eu-jer.10.2.957> Introduction
- Almanasreh, E., Moles, R., & Chen, T. F. (2019). Evaluation of methods used for estimating content validity. *Research in Social and Administrative Pharmacy*, 15(2), 214–221. <https://doi.org/10.1016/j.sapharm.2018.03.066>
- Bond, T. G., Yan, Z., & Heene, M. (2021). *Applying the Rasch Model* (4th ed.). Taylor & Francis.
- Danni, R. (2022). PENGEMBANGAN INSTRUMEN PENGUKUR KEMAMPUAN BERPIKIR TINGKAT TINGGI BAHASA ARAB MADRASAH ALIYAH. *Afeksi: Jurnal Penelitian Dan Evaluasi Pendidikan*, 3(2), 160–167.
- Fardiana, R., Supriyadi, & Djuniadi. (2023). Analisis Kebutuhan Pengembangan Instrumen Penilaian Kemampuan Berpikir Geometri Berbasis Website. *JRPM (Jurnal Review Pembelajaran Matematika)*, 8(1), 63–71. <http://jurnalftk.uinsby.ac.id/index.php/jrpm>
- Fiskawarni, T. H., Rahmawati, Widiastih, & Saad, R. (2024). The Design and Validation of the Four Tier Test Instrument for Energy Literacy Using the Rasch Model Analysis. *Jurnal Ilmu Pendidikan Fisika (JIPF)*, 9(1), 74–87.
- Hamdu, G., Fuadi, F. N., Yulianto, A., & Akhirani, Y. S. (2020). Items Quality Analysis Using Rasch Model To Measure Elementary School Students ' Critical Thinking Skill On Stem Learning. *Jurnal Pendidikan Indonesia (JPI)*, 9(1), 61–74. <https://doi.org/10.23887/jpi-undiksha.v9i1.20884>
- Hamsyah, D., Luzyawati, L., & Yuliana, E. (2021). Validitas Instrumen Penalaran Ilmiah Pada Materi Sistem Pertahanan Tubuh Kelas XI. *Quagga : Jurnal Pendidikan Dan Biologi*, 13(1), 26–33. <https://doi.org/10.25134/quagga.v13i1.3474>
- Holster, T. A. (2023). Conducting a Rasch Analysis in jMetrik. *Shiken*, 27(2), 6–21.
- Larasati, M., Prihatin, T., & Djuniadi, D. (2021). The Development of Evaluation Model Based on Information Technology and Communication. *Innovative Journal of Curriculum and Educational Technology*, 10(1), 51–63. <https://journal.unnes.ac.id/sju/index.php/ujet/article/view/%0AThe>
- Marselina, K. T., Dantes, N., Studi, P., Dasar, P., & Ganesha, U. P. (2021). PENGEMBANGAN INSTRUMEN KEMAMPUAN BERPIKIR KRITIS DAN HASIL BELAJAR IPS PADA SISWA

- KELAS V SD. *Jurnal Penelitian Dan Evaluasi Pendidikan Indonesia*, 11(2), 105–114. <https://doi.org/https://doi.org/10.23887/jpepi.v11i2.620>
- Masuwai, A., Zulkifli, H., & Hamzah, M. I. (2024). Evaluation of content validity and face validity of secondary school Islamic education teacher self- assessment instrument. *Cogent Education*, 11(1), 1–12. <https://doi.org/10.1080/2331186X.2024.2308410>
- Mills, K. A., Cope, J., Scholes, L., & Rowe, L. (2025). Coding and Computational Thinking Across the Curriculum: A Review of Educational Outcomes. *Review of Educational Research*, 95(3), 581–618. <https://doi.org/10.3102/00346543241241327>
- Noorkholisoh, L., Yustiana, Y. R., Budiman, N., & Suryana, D. (2024). Validity and Reliability Analysis Using the Rasch Model in Developing Creativity Tests Instruments for Elementary School Students. *Jurnal Ilmiah Bimbingan Konseling Undiksha*, 15(1), 128–135. <https://doi.org/https://doi.org/10.23887/jibk.v15i1.81249> Validity
- Prasetya, W. A., & Pratama, A. T. (2023). Item quality analysis using the Rasch model to measure critical thinking ability in the material of the human digestive system of Biology subject in high school. *Jurnal Penelitian Dan Evaluasi Pendidikan*, 27(1), 76–91. <https://doi.org/https://doi.org/10.21831/pep.v27i1.58873>
- Sumintono, B., & Widhiarso, W. (2015). *Aplikasi Pemodelan Rasch: pada Assessment Pendidikan*. Trim Komunika.
- Susongko, P., Arfiani, Y., & Kusuma, M. (2021). DETERMINATION OF GENDER DIFFERENTIAL ITEM FUNCTIONING IN TEGAL-STUDENTS ' SCIENTIFIC LITERACY SKILLS WITH INTEGRATED SCIENCE ( SLiSIS ) TEST USING RASCH MODEL. *Jurnal Pendidikan IPA Indonesia*, 10(2), 270–281. <https://doi.org/10.15294/jpii.v10i2.26775>